Exclusive Self Attention

Иван Бобошко

26 октября 2026

Мотивация

Attention собирает информацию не только из предыдущих токенов, но и из самого текущего токена:

$$y_i = \underbrace{\sum_{j<i} a_{ij} v_j}_{\text{контекст}} + \underbrace{a_{ii} v_i}_{\text{собственный вклад}}, \qquad v_i = W_V x_i.$$

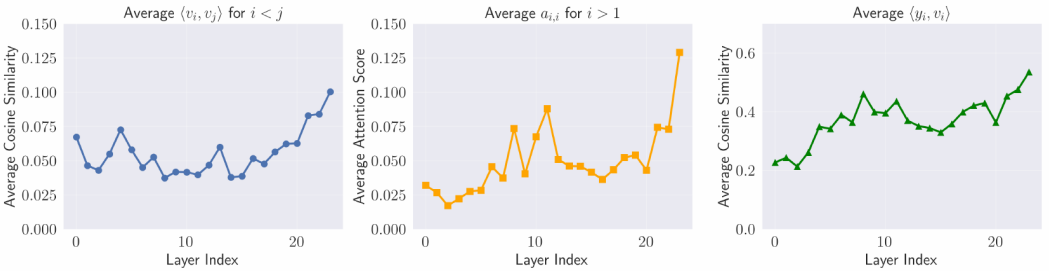
MLP уже выполняет pointwise-преобразование: обрабатывает каждую позицию независимо, не смешивая токены.

$$\mathbb{FFN}(h_i) = W_2\, \sigma(W_1 h_i + b_1) + b_2.$$

Гипотеза: собственный вклад в attention частично дублирует работу FFN. Attention тратит свои ёмкость на pointwise-признаки, конкурирующие с моделированием контекста.

Attention similarity bias

Attention similarity bias – это склонность выхода attention y_i быть направленным вдоль собственного value-вектора v_i:



Слева: сходство разных v_i, v_j. В центре: вес a_{ii}. Справа: сходство y_i, v_i.

Почему недостаточно просто удалить v_i

Корреляция value векторов

$$v_j = \alpha_j v_i + v_j^{\perp},$$

$$\sum_{j<i} a_{ij} v_j = \left(\sum_{j<i} a_{ij} \alpha_j \right) v_i + \sum_{j<i} a_{ij} v_j^{\perp}.$$

Даже без собственного слагаемого выход может быть направлен вдоль v_i.

Диагональный вес как attention sink

- Маскирование диагонали заставляет распределить всю массу по предыдущим токенам, даже если контекст не нужен.
- XSA сохраняет a_{ii}: часть массы можно направить в собственный вклад, который затем удаляется проекцией.

Метод

Сначала считаем обычный attention:

$$y_i = \sum_{j \le i} a_{ij} v_j.$$

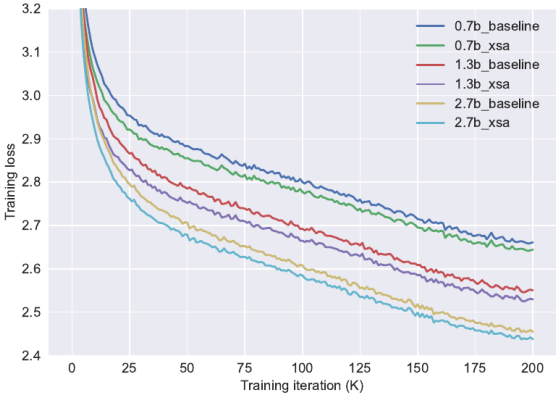
Затем вычитаем компоненту вдоль собственного value-вектора:

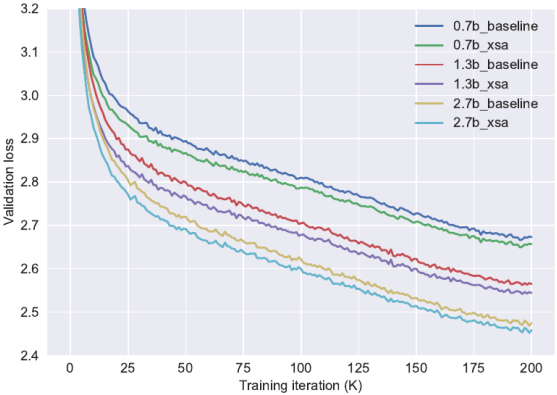
$$\hat{v}_i = \frac{v_i}{\|v_i\|_2}, \qquad z_i = y_i - \underbrace{(y_i^\top \hat{v}_i)\hat{v}_i}_{\text{проекция на направление } v_i}, \qquad z_i^\top v_i = 0.$$

Две строчки

```
v_unit = F.normalize(v, dim=-1)
z = y - (y * v_unit).sum(dim=-1, keepdim=True) * v_unit
```

Результаты

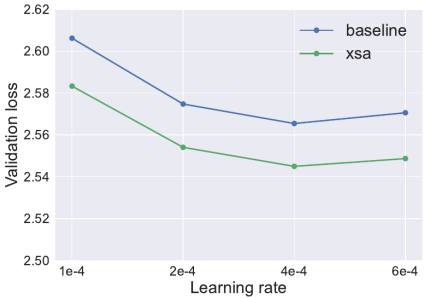




В экспериментах статьи XSA даёт более низкий train и validation loss, чем SA.

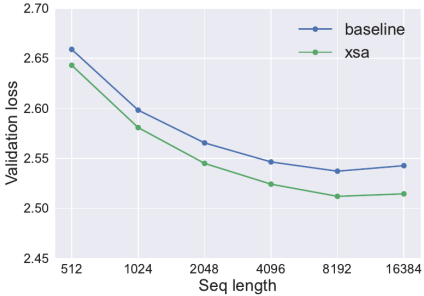
Другие эксперименты

Learning rate



XSA лучше SA при всех проверенных learning rate.

Длина контекста



Выигрыш XSA в целом растёт с увеличением контекста.

Модель 1.3B, validation loss. При изменении контекста число токенов на шаг фиксировано. Графики из Figures 4 и 5 статьи.

Список литературы

Статья
Shuangfei Zhai. *Exclusive Self Attention*, 2026.
arxiv.org/abs/2603.09078

Видео
youtu.be/2eZKT4H9_iQ